

1. Harris este folosit la caracteristici (colturi, muchii, contururi), deci este sigur local.

(plus ca scrie si in titlu)

2. Toate cele trei caracteristici pot fi evidentiata (vertical, orizontal si colt)

3. Cand intalnim A stim ca avem derivata dupa x (muchii verticale), B e derivata dupa x si y (colturi) si C e derivata dupa y (muchii orizontale).

- Avem A, deci e derivata dupa x, deci evidentiaza muchii verticale

4. muchii orizontale

5. - Matricea e de 2×2 , deci are doar 2 valori proprii. (acele eigenvalues)

- Variatia maxima este data de λ_{\max} si are loc pe directia x

6. λ_y si directia y

7. $I_1 \gg I_2 \Rightarrow$ muchie verticala

$I_1 \ll I_2 \Rightarrow$ muchie orizontala

$I_1 \sim I_2 \Rightarrow$ colt

$I_1 \sim I_2$, dar sunt mici \Rightarrow regiune plata / zona uniforma

8. a) $[[0,0],[0,C]], [[A,0],[0,0]], [[A,B],[B,C]]$, adica toate $\neq 0$

9. Translatie, Rotatie, partial invariant la Variatii de intensitate, nu la scalare

10. Invarianta la scalare a detectorului Harris se poate obtine prin doua metode : extragerea feature-urilor la scale diferite , efectuand aceleasi operatii la rezolutii multiple in piramida, sau

extragerea caracteristicilor stabile intre locatie si scala

11. Rezultatul se obtine, cu atat mai bun, cu cat sigma este cat mai apropiat de dimensiunea filtrului (in cazul asta, a petei) (ne gandim la graficul laplacianului, si ne propunem sa avem un peak echivalent ca si dimensiuni cu filtrul), deci aici e 2

12. LoG (Laplacianul Gaussianului) chiar asa se calculeaza; Adica, in mod normal rezultatul este putin diferit fata de calculul efectiv, insa rezultatele sunt comparabile (seamana foarte bine). Cel mai bun rezultat se obtine cand $\sigma = 1.6$ - vezi slide 63/64

Ca si viteza, sunt asemanatoare.

13. LoG include operatiile urm (exact forma asta) : iau filtrul gaussian, il derivez si obtin laplacianul gaussianului si fac produsul de convolutie direct cu imaginea.

La baza, tre sa ne gandim ca e o operatie de mediere.

Deci, intai am mediere si dupa am derivare

14. (ca la 10)

15. IN loc sa efectuam calcule pentru fereste de dimensiuni diverse, este mai bine sa implementam folosind o fereasta fixa peste piramida Gaussian a imaginii.

Deci aplicam un filtru Gaussian, reducand astfel dimensiunea, si pastra

16. Detectie -> Descriere -> Potrivire

17. Am ca scop sa analizez doar diferentele de intensitati din imagine (vreau sa le normalizez) si, pentru a obtine intensitatile diferite dintr-o fereasta, ma raportez doar la cele care sunt diferite de media intensitatilor ferestrei.. deci scazand media, obtin intensitatile. Se imparte la deviatia standard ca sa fac normalizarea, tinand cont de diferentele medii dintre intensitati si medie.

Aceste diferente de intensitati ma ajuta sa compar mult mai usor doua imagini.

18. Descriptori : HOG, FREAK, LIFT, SIFT

Detectori : Canny, Harris, LoG, DoG

19. SIFT este descriptor

20. Muchiile pot avea doar 8 orientari in cadrul descriptorului SIFT (sus, jos, stanga, dreapta si diagonalele, in toate cele 4 directii)

21. Avand in vedere ca tre sa scot in evidenta o muchie, folosesc derivarea (gradient) si, in cazul gradientului, directia de derivare (orientarea) este data de unghiul gradientului - 90 grade

22. Pixelii TP sunt cei marcati cu X, din interiorul figurii segmentate. Pixelii FP sunt cei din interiorul figurii, care nu au X. Pixelii FN sunt marcati cu X, dinafara figurii.

True Positive Rate : $TP / (TP + FN)$

False Positive Rate : $FP / (FP + TN)$

Positive Predictive Value : $TP / (TP + FP)$

Accuracy : $(TP + TN) / (P + N)$

23. Toate sa fie pozitive (falsul sa fie 0). Adica, recall-ul sa fie 1 iar false positive rate sa fie 0.

24. Diferenta dintre 2 gradienti va rezulta in Laplacianul Gaussianului.

25. La coordonate carteziane ($y = mx + b$), parametrii nu sunt finiti, putand lua valori de la $-\infty$ la $+\infty$. In cazul coordonatelor polare, parametrii sunt finiti. (θ in $0, 2\pi$ iar r in $0, r_{\max}$)

26. Curbele obtinute in cadrul reprezentarii Hough sunt pixeli in planul imaginii.

Numarul de curbe care se intalnesc in acelasi punct = numarul de puncte care se afla pe aceeasi dreapta in planul imagine.

27. Nu cunosc vectorul de translatie $[x_t, y_t]$, adica 2 valori, dar cunosc punctele din imagine $[x_i, y_i]$ si $[x_i', y_i']$, deci $2n \times 2$

28. Este exact in curs (inmultesc la stanga si dreapta cu transpusa, pentru a le aduce la aceeaasi dimensiune si asa mai departe)

29. Tot in curs.

Calculez caracteristicile pentru imaginile A si B -> Potrivesc caracteristicile intre A si B -> Calculez homografiile dintre A si B folosind cele mai mici patrute peste setul de potriviri

30. Tot in curs (22/31)

$e = 20\%$

$p = 90\%$

31. Ambele sunt schema de votare

32. Momente = descriptori de regiune. (mai robuste)

Descriptorii de regiune sunt mai putin afectati de zgomot (cu cat iau mai multi pixeli, cu atat sunt mai putin afectate de zgomot).

33. Cea mai mare influenta asupra formei conturului reconstruit o au descriptorii cu valori mai mici.

34. Descriptorii eliptici sunt mai putin sensibili la zgomot, intrucat nu intra in calcul derivatele (acestea amplifica zgomotul)

35. Este exact in curs.

Prima e la elipsa (6104)

A doua e la regiunea convoluta (2316)

A treie a la cerc (4917)

36. parametri intrinseci :

$K = \begin{bmatrix} f & s & cx \\ 0 & \Delta & cy \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 \end{bmatrix}$

37. Lungimea focala poate sa fie gandita ca zoom (lungime focala mare => imi aduce imaginea mai aproape)

38. Nu se poate.

39. Interpun o suprafata sferica intre plan si camera

40. Sunt mai multe solutii in curs.

41. Evitare cusaturi : dimensiune fereastră = dimensiunea celei mai proeminente caracteristici

Evitarea fantomelor : $2 * \text{dimensiunea celei mai puțin proeminente caracteristici}$

42. Laplacian Pyramid Blending

43. Disparitate : diferența dintre coord x și coord x' din imaginea alăturată, raportată la același punct.

$Z(\text{distanța focală}) = f * T / (x_r - x'_l)$

(termenul de la numitor = disparitatea)

44. Constangerile epipolare au rolul de a restrange căutarea corespondentei, de la 2D la 1D (pe o linie)

45. Aducerea liniilor epipolare pe direcția orizontală, ca să fac căutarea mai ușoară.

46. Da, avem nevoie de o intensitate luminoasă constantă. Dacă cumva nu avem, încercăm să normalizăm imaginile, scăzând media și împărțind la dispersie.

47. Energy Minimization este mai bun întrucât, pe lângă potrivire, are în vedere și o netezire (pixelii alăturați se comportă la fel)

48. Având mai multe imagini ale aceluiași obiect sau scene, compunem o reprezentare 3D a formei acestuia. imaginile tre să fie calibrate.

49. La SSD și SAD, imaginea își păstrează caracteristicile de iluminare.

Cel mai bun este NCC (scad media din fereastră și împart la sigma, adică se normalizează)

50. Se poate utiliza atunci când obiectul respectiv este neocluzionat și să apară la aceeași slava, fără rotire.

51. imagini distincte, să nu fie imagini generice

52. poziția, iluminarea, forma, scala, variația punctului de observare, amestec cu fondul, ocuziile

53. la cele intra-clasă, varianta tre să mică, pe când la între clase tre să fie mare.

54. Valoare optimă : setul de antrenare

hiperparametri : set de validare

precizie : set de testare

55. clasificatori : toți (Nearest Neighbour, KNN), Linear Classifier, Neural Network, Deep Neural Network

Detectori : niciunul

56. pierderi în setul de antrenare (verde) < pierderi în setul de testare (albastru)